



上海交通大学

SHANGHAI JIAO TONG UNIVERSITY

研究生学位论文开题报告

Graduate Thesis/Dissertation Proposal

学号 Student ID	022033910112
姓名 Name	王玥天
学生类别 Degree Program	学术型博士生 Academic Doctoral Student
学习形式 Study Mode	全日制 Full-time
导师 Supervisor(s)	史殿习
论文题目 Thesis Title	基于模型的智能体策略学习与优化技术研究
学院 School	电子信息与电气工程学院
专业 Major	计算机科学与技术
开题日期 Date	2024-10-23
开题地点 Venue	会议室

填 报 说 明

Instruction

1. 校本部研究生的开题报告应通过[数字交大](#)在线提交申请，填写本表并上传系统。特殊情况下经研究生院事先同意，可不上传系统，并使用《上海交通大学研究生论文开题评审表》完成评审。

The application for thesis/dissertation proposal should be submitted online through [My SJTU](#). The student shall fill this form and upload it in the system. Under special circumstance, this form does not need to be uploaded and the review can be proceeded with the review form with prior consent from the graduate school.

2. 开题报告为 A4 大小，于左侧装订成册。各栏空格不够时，请自行加页。考核前提前一周送交导师、评审专家审阅。

This form should be printed with A4 papers and bound together on the left. If the space left is not enough, please feel free to add extra pages. The print version shall be sent to the supervisor, and the review committee members for review at least one week before the oral presentation.

3. 博士生导师可以根据博士生学位论文选题情况自行确定是否进行开题查新，博士学位论文开题查新报告应由查新工作站提供。

The supervisor should decide, based on the proposed topics, whether a novelty assessment report is needed or not, which should be conducted by an authorized novelty assessment department.

4. 开题报告通过后，定稿版开题报告由研究生、导师各存档一份，无需上传系统。

Upon passing the proposal, the final version of this report shall be archived by the graduate student and his/her supervisors for future reference.

5. 同等学力研究生开题答辩采用会议形式，硕士邀请至少 3 名相关学科/专业领域具有硕士研究生指导资格的专家。博士邀请 5 名相关学科/专业领域具有博士研究生指导资格的专家。

The capstone presentation adopts a conference format, and at least three experts with master's degree guidance qualifications in relevant disciplines and professional fields are invited for the master's degree. And five experts with doctoral guidance qualifications in relevant disciplines/professional fields are invited for doctoral guidance.

论文题目 Proposed Title	基于模型的智能体策略学习与优化技术研究
研究课题来源 Source of Research Project	请在合适选项前画 ✓ Please select proper options by “✓”. ☒ 国家自然科学基金课题 NSFC Research Grants ☐ 国家社会科学基金 National Social Science Fund of China ☐ 国家重大科研专项 National Key Research Projects ☐ 其它纵向科研课题 Other Governmental Research Grants ☐ 企业横向课题 R&D Projects from Industry ☐ 自拟课题 Self-proposed Project ☐ 其它 Other 在此处填写内容 _____

- 1、请综述课题国内外研究进展、现状、挑战与意义，可分节描述。博士生不少于 10,000 汉字，硕士生不少于 5,000 汉字。请在文中标注参考文献。Please review the frontier, current status, challenges and significance of the research topic. The citations should be marked in the context and listed in order at the end of this section. No less than 8,000 words for doctoral students and 4,000 words for master students if written in English.

强化学习（RL）通过与环境交互的试错过程来解决顺序决策问题，研究了提高智能体自主顺序决策性能的方法。深度强化学习算法自提出以来，在虚拟场景中取得的一系列成就甚至显示出超越人类决策能力的潜力，因此将其应用范围扩展到包括现实世界的任务是非常值得关注的研究方向。

1.1 国内外研究进展与现状

近年来，从阿尔法 go 打败李世石以后，人们对于深度强化学习的关注和热度不断飙升，相关研究发展也日渐蓬勃。随着计算能力的发展和深度学习技术的提升，深度强化学习从学术界到产业界取得了重大进步。在一系列复杂的决策任务中展示了出色的表现，包括在雅达利游戏和围棋上已呈现出超越人类的表现^[1-2]，在机器人学习领域的运动和操作技能控制上^[3-6]几乎可以达到与人类相同的表现。

通常来讲，深度强化算法需要大量的训练样本进行学习探索，这导致了其样本复杂度非常高。在一般的强化任务中，特定算法的样本复杂性指的是学习近似最优策略所需的样本量。典型的强化学习算法与从历史标记数据中学习的监督学习范式不同，前者通常需要通过在环境中运行最新的策略来获得交互数据。而一旦策略更新，基本数据分布（正式意义上的数据占用率）就会发生变化^[7]，这样就必须通过运行策略再次收集数据。因此具有高样本复杂度的强化学习算法很难直接应用于现实世界的任务，这是因为在现实世界中，试错成本可能高到难以支付。例如现实中的救灾机器人，需要面对的环境非常危险，机器人造价也非常昂贵，显然这种任务下是满足直接交互的样本采集需求是不现实的。包括在一些成本敏感的场景中，例如自动驾驶，工业控制，智慧城市电力分配等等现实复杂场景中，试错的代价是非常高昂乃至不可接受的。

也正是因此，近些年来对深度强化学习（DRL）的研究主要集中在提高样本效率上^[8]。在不同的研究分支中，基于模型的强化学习（MBRL）是最重要的方向之一。从交互介质出发，强化学习（RL）方法通常分为两类：一类是无模型强化学习（MFRL），这类方法直接从观测数据学习策略或值函数，也就是学习从状态到动作的一个直接映射；另一类是基于模型的强化学习（MBRL），这类方法则建立一个环境的预测模型并生成样本的策略或控制器。正如前文所述，虽然 MFRL 算法在不同的领域取得了显著的成功，显示出了作为从原始状态输入中学习复杂策略的通用工具的潜力，但是这都建立在需要大量样本的基础上。在处理现实世界的物理系统时，数据的收集通常是一个艰巨的过程，也正是因为这样的样本效率问题，这些方法的应用主要局限于虚拟或是模拟环境中。相比之下，基于模型的方法在降低样本复杂性方面显示出了巨大的潜力^[8]，也因其相对快速的学习速度而具有吸引力。基于模型的深度强化学习明确地利用了来自状态观测的信息，通过使用估计的动态模型进行规划，这被认为是一种很有前途的降低样本复杂性的方法。因而研究人员们普遍认为它具有使 DRL 算法显著提高样本效率的巨大潜力。这种想法的非常直观地来源于与人类智慧的类比。人类能够在脑海中拥有一个想象的世界，在这个世界中，人类可以预测不同的行为会发生什么后果。通过这种方式，人类和智能体都可以从想象中

选择适当的行动，因此具有较低的试错成本。MBRL 中的模型是期望发挥与想象相同作用的环境模型。在这个环境模型中，试错可以发生而不产生实际成本。事实上，一些实验验证的结果^[9-11]也显示了基于模型的强化学习方法中样本效率的显著提高。

但是在基于模型的方法中，由于预测模型的存在，模型精度或者说模型的准确度通常是制约着策略质量的瓶颈，这是因为学习到的模型不可避免地会有一定程度的不准确性，导致在模拟事件时出现复合误差。而模型与实际环境的偏差通常导致基于模型的方法在渐近性能上不如相近水平的无模型对应方法。MBRL 方法的理论界限渐近性往往滞后于同样程度的无模型方法。由于复合误差的存在，这一问题在使用多步推导模型时尤其严重。而且在复杂高维环境的各种 DRL 任务中学习理想的模型也并不简单。因此，我们必须仔细考虑模型学习和应用策略。基于此，下面将从模型方法中模型的学习，模型的使用，以及基于模型方法的优势三个方面进行继续综述相关研究。

1.1.1 模型的学习

在 MBRL 中，环境模型（或简称模型）是指学习代理与之交互的环境动力学的抽象。有了环境模型，智能体就可以拥有想象能力。智能体可以通过与模型交互对数据进行采样，也称为模拟数据。理想情况下，如果模型足够准确，就可以在模型中学习到一个好的策略。对于 MBRL，首先要考虑的是环境模型的学习。RL 中的动力学环境通常被公式化为马尔可夫决策过程 (MDP)，用 (S, A, M, R, γ) 表示，其中 S ， A 和 γ 表示状态空间、动作空间和未来奖励的折扣因子。通常，在给定状态和动作空间以及折扣因子的情况下，环境模型的关键组成部分是状态转换动力学和奖励函数。在许多情况下，奖励函数也被明确定义，因此模型学习的主要任务是学习状态转换动力学^[6,12]。我们假设有一些历史数据可供学习。通常，历史数据可以定义为轨迹的形式 $\{\tau_1, \tau_2, \tau_3 \dots \tau_k\}$ ，并且每个轨迹是状态-动作-奖励对的序列。我们可以很容易发现，这些数据记录了与转移动力学 M 的输入和输出相对应的过去的转移 (s_t, a_t, s_{t+1}) ，以及与奖励函数 R 的输入和输出相对应的过去奖励 (s_t, a_t, r_t) 。因此，借用监督学习的思想进行模型学习是直观且简单的。

在强化学习研究的早期阶段，状态和行动空间都是小且有限的。此时模型学习通常用表格 MDP 来考虑^[13-15]，其中策略、转移动力学和奖励函数都可以记录在表中。虽然在表格 MDP 设置下的计数方法和模型学习理论是明确的，但对大规模 MDP 和具有连续状态空间和动作空间的 MDP 使用表格表示是不可行的。因此，在一般设置中人们经常使用近似函数。近似函数可以通过机器学习模型来实现，如线性模型、神经网络、决策树模型等。在后续工作的一个研究点中，我的主要关注点在使用神经网络模型来作为近似函数的方法。

作为最简单直接的模型学习方法，单步转移^[16-18]已经被广泛地应用。当转移模型是确定的时，模型学习目标可以定为模型对下一状态的均方预测误差。但是确定性转移模型是无法捕捉到由环境固有的随机性引起的任意不确定性的。因此我们还需要对任意的不确定性进行建模，针对这点的一个直接想法是利用概率转移模型^[19]。在这种情况下，模型学习的目标通常可以是最小化概率转移模型与真实的转移动力学之间的 KL 散度。在已有的实践当中，概率转换模型通常被实例化为高斯分布。在使用相应的公式来预测模型损失时，可以发现模型学习任务转变为了监督学习任务。此时任何监督学习技术都可以用来实现高效的模型学习。

当我们在使用预测模型损失方法来获得模型时，最需要关注的是该模型能在多大程度有用，特别是获得的策略在模型和实际环境中的表现有多不同，即价值评估误差。在这部分，已经有研究人员^[20]推导了模型误差带来的损失，还有研究人员过将模型误差 m 与模型学习的样本和模型空间进一步相关，提供了评估误差的有限样本复杂度结果。在此基础上，我们可以考虑一些能够缓解复合误差的模型变体的内容。由于复合误差是由使用单步转移模型的递归状态动作生成引起的，因此缓解该问题的一种方法是一次预测多个步骤。基于这种思想，Asadi 等人^[21]提出了多步骤模型，即以当前状态 s_t 和步长为 h 的一系列动作 $(a_t, a_{t+1}, \dots, a_{t+h})$ 为输入，并预测未来的 h 步状态。一个确定性的多步骤模型可以表示为： $(s_{t+1}, \dots, s_{t+h}) = M_{\theta}^h(s_t, a_{t+1}, \dots, a_{t+h})$ ，该模型也可以通过监督学习来训练。显然能看出来，和单步模型相比，多步模型不将预测的“假”状态作为输入，因此可以避免 h 步内的复合误差。但是与此同时，跨多步的动力学模型可能比单步动力学复杂得多，因此，多步转移预测模型可能具有

更大的误差。

前面讨论的转移模型都是正向模型，即随时间的发展顺序正向预测。除了正向模型外，MBRL 中也存在对反向转移模型的研究^[22-26]。反向转换模型将未来状态 s_{t+1} 和动作 a_t 作为输入，并预测状态 s_t 。反向模型通常用于生成反向数据，这有助于缩短推测时间，并可以提高 MBRL 的样本效率。从前面的模型性质中，我们可以看出，水平平方复合误差是模型学习的一个主要问题。这个问题主要是由使用预测损失来学习无约束模型带来的。为了减少复合误差，有一种经典的方法是给模型添加约束，如 Lipschitz 连续性约束等。Venkatraman 等人和 Asadi 等人^[27-28]就是这么做的。他们首先采用 Wasserstein 距离^[29]来测量两个分布之间的相似性，并证明了 Wasserstein 距离在转移分布差异测量指标上的优越性。这类方法中采用的预测损失使得状态动作数据的每个点上的误差最小化。虽然预测损失最小化可以通过监督学习直接解决，但很难捕捉到转变的长期影响，导致了水平平方复合误差问题。

环境动力学模型的主流实现手段通常是一系列的高斯过程，在这个过程中下一个状态分布的均值向量和协方差矩阵是基于当前状态-动作对中的神经网络构建的^[19]。这种架构在 MuJuCo 机器人运动^[30]中有着非常出色的表现，这是因为在 MuJuCo 环境中的状态观测值足以用于未来状态的推导，然而现实中还存在许多复杂的环境是难以通过类似方法直接建模的。这就是我们实际中更常遇到且需要解决的部分可观测问题。部分可观测性^[31]是指智能体无法对当前环境进完整有效地观测，无法从环境中获得足够的观测信息来对未来状态进行推导，例如单纯一帧静止的画面无法提供物体移动的速度。这就使得环境需要被建模成为部分可观测马尔可夫过程 (POMDP)。对于 POMDP 中的模型学习，经典的解决方案是采用置信状态估计，也就是通过最大化后验来学习观测模型和潜在转移模型，并且可以推断后验分布。在此基础上利用深度学习，可以通过递归神经网络获得潜在状态分布。对于图像等高维状态空间，表征学习这样能够学习信息潜在状态或动作表示的方法有利于环境模型的构建，从而提高基于模型的 RL 在不同方面的有效性和采样效率，包括价值预测和模型推广。Schmidhuber 等人^[32]在 2018 年将自动编码器网络引入 RL 方法，通过对潜在状态进行编码，可以达到有效重建图像的结果，自此提出了世界模型的思路，即

通过预测未来的范式对数字世界和物理世界进行理解。Hafner 等人提出 Dreamer 方法^[33]，学习了视觉控制任务的潜在动力学模型，提出了基于学习经验收集的视觉编码器和潜在动力学的环境模型（本工作的世界模型），并且该模型被证明具有执行长时间推出和值估计的能力。在此基础上，Hafner 等人进一步提出了 DreamerV2^[34]，它支持智能体纯粹从模型推出的数据中学习，并在 55 个雅达利游戏任务上实现人类级别的性能。与 Dreamer 相比，DreamerV2 用离散分布取代了他们早期工作 PlaNet^[35] 中提出的高斯分布，因此带来了算法性能的优化。造成这种影响的一个可能原因是离散的潜在表示可以更好地拟合聚合后验并且处理多模态情况。此外考虑到模型训练和使用模型阶段之间的状态-动作对分布不匹配问题，Shen 等人^[36]把领域自适应目标纳入模型学习任务当中，以鼓励模型去学习真实数据和模拟数据之间的状态-动作对的确切表征。近两年世界模型领域产出了非凡的成果，众多研究人员均认为是通往实现通用人工智能（AGI）的关键路径之一。视频生成领军企业 Runway 在技术博客中表示，文生视频系统 Gen-2 的下一代产品将会通过通用世界模型来实现。在自动驾驶领域，Tesla 和 Wayve 均表示在利用世界模型的预测未来特性构建其端到端自动驾驶系统。在更广泛的通用机器人智能领域，LeCun 多次在演讲中表示对世界模型潜力的极大关注，并预言世界模型将会取代自回归模型成为新一代智能系统的基础。在高维感官输入场景中，世界模型利用潜在的动力学模型来抽象地表示观测到的信息，从而能够在潜在状态空间内进行紧凑的前向预测。由于深度学习和潜在变量模型的进步，这些潜在状态比高维数据的直接预测更具空间效率，有助于执行许多并行预测。以十字路口汽车方向的模糊性为例，这种情况象征着现实世界动力学固有的不可预测性。潜在变量是表示这些不确定结果的有力工具，为世界模型设想基于当前状态的一系列未来可能性奠定了基础。这项努力的关键在于将预测的确定性方面与现实世界现象的内在不确定性相协调，这是世界模型功效的核心平衡行为。除了前文提到的核心是采用递归状态空间模型（RSSM）的 Dreamer 系列相关工作，还有另一系列联合嵌入预测架构（JEPA）等结构化框架的方法^[39-41]^[37-39]也有突出表现。联合嵌入预测体系结构（JEPA）通过关注表示空间而不是直接、详细的预测，标志着预测建模的范式转变。通过抽象输入 (x) 和目标 (y) 通过双编码器转换为表示 (s_x, s_y)，并利用潜在变量 (z) 参与预测，JEPA 在效率和准确性方面实现了显著的

飞跃。该模型擅长滤除噪声和不相关信息，专注于预测任务的本质。潜在变量的战略使用 (z) 管理不确定性进一步细化了模型的重点，使其能够更精确地预测抽象结果。通过优先考虑相关特征并包含预测任务的固有不确定性，JEPA 不仅简化了预测过程，还确保了结果的相关性和可靠性，为复杂环境中的预测建模树立了新标准。

1.1.2 模型的利用

当我们构造出一个可用的模型时，接下来的关键是如何使用这个模型，即如何利用模型进行智能体策略的学习，我们将在这部分探讨这个问题。模型的利用方法大致可以分为三类，一是使用学习到的模型模拟扩充训练样本数据也即数据增强，然后是需要决策时间模型模拟，在模型中进行规划的方法，最后是使用可微模型进行梯度生成的方法。前面两种方式是不利用模型内部结构的，而第三种方法则需要了解并利用模型内部结构与知识。

我们可以通过使用一个模型来根据需要生成任意数量的模拟样本。我们可以使用模拟数据进行策略学习或值逼近。这种策略/价值学习和模型的集成被称为 dyna 风格的方法。dyna 式的方法^[40]利用学习到的过渡模型来生成更多的经验，然后对由模型经验增强的数据集执行 RL。因此，在 dyna 风格的方法中的模型被视为策略的数据扩充器。模型的主要目的是生成策略学习的模拟经验。在价值学习类方法中，MC 值估计^[41-42]是近似状态值的原始方法。MC 值估计描述了一个原始模型使用的值近似，即平均模拟轨迹的累积奖励。另一种值逼近方法则是时间差分 (TD) 预测^[43]，它广泛应用于许多基于值的 RL 方法^[1-2]，与 MC 方法相比，一步 TD 不需要环境模型，因此是许多无模型方法的首选。范伯格等人^[17]提出了基于模型的值展开 (MVE)，表明 H 步 TD 值预测在某些条件下可以减少值估计误差，其主要原理是通过展开 H 步的模型动力学来形成 H 步 TD 目标。然而，MVE 依赖于固定的水平 H ，这是特定于任务的，可能在不同的训练阶段和状态空间中发生变化。随机综值展开 (STEVE)^[44]基于系综计算的不确定度，通过在不同视野之间进行插值，进一步改进了 MVE。相对值学习，策略学习类方法则更广泛和普遍，且这类模型增强的数据也可以被 MFRL 方法用于策略改进。习到的动态模型可以看作是一个可以训练策略的模拟器。Kurutach

等人^[16]提出了模型集成信任区域策略优化 (ME-TRPO)，该优化通过 TRPO^[6]从一组学习到的模型中学习策略。训练过程在使用当前策略收集数据，使用环境数据训练集成模型，以及改进集成模型中的策略之间进行迭代。每个模型都是通过最小化预测误差从真实的轨迹中学习出来的。当与集成模型交互时，ME-TRPO 在每一步中随机选择一个模型来预测给定当前状态和动作的下一个状态。收集到的想象轨迹通过 TRPO 更新策略。此外，Luo 等人^[8]从理论的角度研究了这种学习框架，提出了随机下界优化 (SLBO)，可以看作是 METRPO 的一个变体。它的训练过程与 ME-TRPO 非常相似，但使用了多步骤的 L_2 -范数损失来训练动力学。SLBO 是基于理论保证而构建的，但仍然存在一个问题。SLBO 使用该模型从开始状态开始推出整个轨迹。但是，由于模型的复合误差，我们可能不会推出这么长的时间。另一方面，基于模型的策略优化 (MBPO)^[12]对模型中的分支推出进行了采样。MBPO 从在真实环境中采样的状态开始推出产生模拟数据，并根据策略 π 和学习到的模型 p_θ 运行 k 步。此外，MBPO 还采用了非策略 RL 算法 SAC^[3]，利用真实环境和学习模型的混合数据对策略进行更新。MBPO 还给出了一个具有模型偏差和 k -分支推出的单调改进定理。在 MBPO 提出的基于正向预测建立模型，推导真实环境回报推出 rollout 方案基础上，Lai^[45]等人认为可以加入反向模型，使之与正向模型同时作用来生成用于策略优化的 rollout。这样可以产生更有效的 rollout，这是因为考虑到在做出决策时，人类不仅可以向前预测当前行为的未来后果，还可以向后想象导致目标目标的可能轨迹。在反向模型领域的相关工作中，Edwards^[22]等人研究了如何最大限度地利用环境的潜在动力学来减少对正向预测模型准确性的依赖。由此，Lai^[45]等人提出了 BMPO 方法，BMPO 引入了一个反向动态模型和一个反向策略来完成反向轨迹采样。具体来说就是考虑给定一个状态和先前的动作，后向模型则可以预测先前的状态，这意味着它可以生成终止于某个特定状态的轨迹。也就是说，如果同时使用正向模型和反向模型从一些遇到的状态双向采样进行策略优化，模型误差将在不同的方向上单独复合。Lai^[45]等人实验证明了分别使用正向模型和双向模型生成相同长度的轨迹时，后者的复合误差将小于前者。Pan 等人^[46]提出了一种基于掩蔽模型的演员批评者 (M2AC)，该方法可以通过丢弃具有高不确定性的样本，选择更长的推出长度来更好地利用模型。M2AC 通过测量一个模型与集成模型中其他模型之间的不一致来计算每个样本

的不确定性，并且只存储一批不确定性最小的样本。dyna 风格的方法可以自然地集成模型学习和 MFRL。这些方法具有令人印象深刻的性能和理论边界。因此，dyna 风格的算法在 MBRL 社区中吸引了大量的研究兴趣。这些方法的一个常见和重要的问题是如何解决或减轻复合误差。如何使用该模型来生成更可靠的数据，以及如何更好地利用想象中的数据仍是一个有待解决的问题。

其实当我们构造出一个可用的模型时，关于如何使用这个模型最直接的想法是让智能体在这个模型中进行规划。在这里，规划是指以模型为输入并产生或改进与建模环境交互的策略的任何计算过程。首先是模型预测控制（MPC）。MPC 是一种基于模型的控制方法，它在模型中规划最优动作序列。经典的 MPC 方法需要设计参数模型和策略以适应优化器，例如线性二次型和相应的二次优化求解器。而基于学习的 MPC 与 MBRL 有着紧密的联系，特别是对于非线性模型和黑盒模型。通常来说，MPC 通过在每个时间步长中对多个序列进行采样并将序列的第一个动作应用于环境来获得最佳动作序列。黑盒 MPC 将这个模型视为一个黑盒优化问题，并采用一些零阶优化方法来求解。此外还有蒙特卡罗（MC）方法（也称为“随机射击”），这是一种非常基本的优化方法，该方法从动作序列的空间中均匀随机地采样多个动作序列： $t + \tau$ 。通过应用模型中的动作序列，可以将当前状态 s_t 转换为遵循分布的 $s_{t+\tau}$ 。在转换过程中累积的回报则用于评估动作序列，评价最高的动作序列就作为优化问题的解。MC 方法实现起来非常简单，并且不需要许多计算资源。然而由于随机采样过程的低效率问题，它不仅存在高方差问题，而且当动作空间很大时可能无法对高回报的动作序列进行采样。用 CEM^[47]、PETS^[19]和 PlaNet^[35]替代 MC 方法可以提高优化效率。CEM 不是随机均匀抽样，而是从多元正态分布抽样，并根据采样序列的评估进行调整，使高奖励序列的概率具有更高的采样。其他的优化方法也可以集成到 MPC 框架中。除了改变优化方法外，POPLIN-A^[48]通过将采样空间改变为动作偏置空间进一步提高了优化效率。MCTS^[49-52]是蒙特卡罗抽样方法的一种扩展，它通过树搜索来提高采样效率。MCTS 通过在搜索树中扩展和剪枝节点来选择最佳动作。MPC 和 MCTS 总是在智能体遇到新状态后开始并完成规划，这种方法又称为决策时间规划^[10]。另一种规划方法是背景规划，它利用从模型中获得的模拟数据来改进策

略或价值学习^[10]。动态规划^[10]、表格 Dyna^[40,53]和优先级扫描^[54]都属于后台规划方法。VIN 揭示了经典的 VI 规划算法^[55]可以用一种特定类型的卷积神经网络 (CNN) 来表示。通过将一个奖励张量传递给 CNN，然后传递一个最大池化层，可以实现 VI 的一个步骤。他们将这样一个模块嵌入到一个标准的前馈网络中，从而获得一个神经网络模型，该模型可以学习隐式规划，并为策略提供有用的规划结果。前面我们将动态模型看作是一个黑盒，用它我们可以将一个状态转移到另一个基于一个动作条件的状态。然而，在许多 MBRL 场景中，动态模型是可区分的。动态模型可以是神经网络^[56]、高斯过程^[11]或可微物理引擎^[57]。我们可以利用模型的内部结构来促进策略学习。学习控制的概率推理 (PILCO)^[11]通过高斯过程^[58]建模动态模型。虽然 PILCO 对于策略梯度具有优雅的数学形式，并且能够自然地通过高斯过程估计模型 (GP 模型) 的不确定性，但其 GP 模型在高维环境中难以扩展。为了提高 PILCO 的可伸缩性，Gal 等人的^[59]用贝叶斯神经网络代替了 GP 来模拟动态^[60]。他们将 PILCO 扩展到高维数，并保留了 GP 模型的概率性质。对于由公共神经网络实例化的动态模型，如全连接或卷积神经网络，可以通过学习到的模型^[61]进行反向传播来估计策略梯度，随机值梯度 (SVG)^[56]是其中的经典。它将为模型预测引入一个似然比项，并增加梯度估计的方差。相反，MAAC^[62]、Dreamer^[33]和 IVG^[63]完全依赖于模型的预测，消除了对似然比项的需要。由于神经网络模型被广泛应用于模型学习，基于白盒模型的方法可以自然地应用于这些模型。这些方法可以直接计算 RL 目标的梯度行动序列的策略。因此，这些方法有可能改变试验和错误的探索以及策略改进范式的梯度下降。然而，由于模型误差的存在，这些方法目前存在梯度偏差。如何减少梯度偏差和方差是这类方法的未来发展方向。

1.1.3 基于模型方法的优势

显然，基于模型的 RL 有一些天然的优势，通常体现在这些方面：使用规划（增加的模型样本复杂度）来降低现实世界的样本复杂度；其次，使用模型特征可以获得更好的探索方法。三是基于模型的 RL 与已知模型达到更高的渐近性能（最优/累积奖励的潜力）。第四个潜在的好处是转移。它试图通过利用共性来降低一系列任务

上的样本复杂性。最后，基于模型的 RL 方法可以提供更好的安全性和可解释性。在样本复杂度方面，前文已经进行了丰富的阐述，简而言之，基于模型的 RL 具有通过两阶段探索来提高数据效率的强大潜力。通过学习环境的动力学模型，预测不同动作带来的状态变化，而不需要每一步都依赖真实环境进行交互。这种方法减少了对现实世界中昂贵的、危险的或难以获得的数据的需求。这类方法允许智能体在模拟的环境中快速探索和优化策略，大大减少了在真实环境中需要的交互次数。通过学习世界的模拟（通常是图像和物理动力学），将环境进行高度抽象，这种抽象化加速了学习过程，并且能够更快地收敛到有效的策略。总体而言，MBRL 通过在模拟环境中进行预测和训练，降低了对现实世界样本的需求，大大提升了样本效率，尤其在高成本或高风险的实际应用场景中展现了巨大的优势。这也是我们从事基于模型的 RL 研究的原始动力之一。

另一个优势则是在探索上。在强化学习中，探索是一个重要的问题。探索和利用之间的权衡是强化学习中的一个关键主题，其中基于模型的方法可以发挥重要作用。基于模型方法的方法在探索时更贴近人类的思考，这类方法通常认为人们自主探索的一大动力来自于降低外部环境的不确定性^[64]。人在发育过程中逐渐形成对于环境运行的知识，大脑因此对未来的观测状态存在自上而下的期望，当未来状态与该期望差异明显时，“好奇心”“惊奇”“学习提升”“多样化”等启发性信息将会驱使个体对这一现象进行探究。这种认知现象在自适应共振^[65]和内在动机^[66]等理论中都有描述。这类照此不断修正自我认知的 DRL 探索方法，可以更好地模拟人类的探索行为，从而提高探索的效率。

基于模型的方法为智能体建立和维护一个对动作结果和状态转移进行预测的模型，以模型精度表达外部环境的不确定性。以此预测模型为基础，智能体根据某些新颖性或可预测性的衡量指标学习价值函数或策略。依据产生内在奖励指标的不同，基于预测模型的方法可以分为基于预测误差、预测结果不一致性和预测精度提升的方法。首先是基于误差的方法。早在 DRL 成为研究热点之前，基于预测误差的强化学习方法就已受到关注^[67-69]。预测误差是指预测模型的输出与预测对象的真实取值之间的差别，用来形式化“惊奇”“好奇心”等概念。也被称为对抗式好奇心^[70]。这类方法在预

测对象是可学习的、确定性的或带有同质噪声的情况下,学习效率较高^[71]。然而,在更实际或复杂的场景中,它们容易被环境中的不可控成分(如白噪声)严重影响,而陷入局部状态空间中,导致探索进程受阻。因此这类方法的研究重点在于预测模型的建构(包括对状态的表示和/或对动力学的预测)能否有效反映与探索相关的观测信息。较早期的工作包括 Stadie 等人^[72]2015 年提出的模块化框架:对观测状态进行特征提取 $\sigma: S \rightarrow \mathbb{R}^d$, 再为智能体建立动力学预测模型 $\mathcal{M}: \sigma(S) \times A \rightarrow \sigma(S)$. $\sigma(s_t)$ 由自编码器的隐藏层提供, $\sigma'(s_{t+1}) = \mathcal{M}(\sigma(s_t), a_t)$ 则由全连接网络训练得到, 而内在奖励则是预测误差 $e(s_t, a_t) = \|\sigma(s_{t+1}) - \sigma'(s_{t+1})\|_2^2$ 的函数。虽然该算法实现了构建正向动力学预测模型, 以预测误差的形式提供内在奖励, 但是其编码器易受来自环境的随机噪声干扰, 且在部分 Atari 游戏上相对 Boltzmann 策略 Thompson 采样和 DQN(deep q-network)^[72] 的优势比较有限。除正向的动力学预测模型外, Pathak 等人^[61] 为去除状态表示中与智能体动作无关的随机部分, 设计逆动力学模型 $\hat{a}_t = g(\phi(s_t), \phi(s_{t+1}); \theta_1)$ 从状态转移中预测动作。其中, ϕ 为状态表示函数, θ_1 为逆动力学模型的网络参数。此模型与正向模型 $\hat{\phi}(s_{t+1}) = f(\phi(s_t), a_t; \theta_F)$ 联合, 以自监督学习方式进行训练, 同时以状态预测误差的 2 范数平方为内在奖励训练智能体的动作策略。内在好奇心生成模型称为 ICM (intrinsic curiosity module) 算法。在稀疏奖励下的 VizDoom^[73] 环境的导航、空间探索任务下 ICM 算法的均分是当时的 SOTA 算法 VIME^[74] 的 2 倍以上。ICM 算法依靠逆动力学模型可以在一定程度上缓解白噪声问题, 但是其仅考虑动作的即时效果, 无法解决长周期决策中动作效果延时的问题。与 ICM 算法类似, Kim 等人^[75] 提出的 EMI (exploration with mutual information) 算法除构建正向动力学预测模型外, 也构建了相似的动作预测模型, 但其在状态和动作的嵌入向量基础上人为施加线性的动力学约束和误差。此外, EMI 算法将嵌入特征和动力学模型的学习与内在奖励的生成分离, 规避了 ICM 算法中逆动力学特征 (inverse dynamics features, IDF) 预测误差不稳定的问题^[76]。在探索难度较大的 Atari 游戏和机器人控制任务中 EMI 算法取得了相较 EX^[77], ICM^[76], AE-SimHash^[78] 等方法更优或可比的结果, 但是无法有效应对长周期决策问题。为探究不同的状态特征提取方法和不同测试环境对基于动力学模型的 ICM 效果的影响, Burda 等人^[79] 将像素级特征 (pixels)、权重随机初始化后固定其权重的网络的输出特征向量、变分自编码器 (variational autoencoders,

VAE)^[80]和 ICM 算法的 IDF 分别作为 ICM 算法中的 $\phi(s_t)$ 。在不同类型的 54 个测试场景的实验结果表明, 利用 Pixels 特征难以学到有效的预测模型, 基于 VAE 的好奇心模块则表现不稳定; 但意想不到的是, RF 则在所有环境中取得了与 IDF 相当的表现, 但其在向未见过的新环境泛化时不如 IDF。上述结果说明, 即使随机的特征提取也能较好地用于表征状态间的差异, 从而表达出环境信息的不确定性。另外, 当面对状态转移随机性较强的环境 (如存在 noisy TV 等白噪声干扰) 时, RF 和 IDF 的学习效率都受到剧烈影响。相对 IDF 特征, 随机网络输出的特征是确定的, 不随训练过程而改变, 因此能够提供更稳定的预测误差。基于这一观察, Burda 等人^[81]提出非动力学的预测误差形式化算法, 即预测对象并非状态转移, 而是状态的嵌入式特征向量。预测目标产生于随机初始化且权重固定的神经网络 $f: S \rightarrow \mathbb{R}^k$, 预测信号则来自于同结构的预测网络 $\hat{f}: S \rightarrow \mathbb{R}^k$, 其训练目标是均方误差 $\|\hat{f}(s; \theta_{\hat{f}}) - f(s)\|_2^2$ 的最小化, 即将随机网络的权重向预测网络蒸馏。因此这一算法称为随机网络蒸馏 (random network distillation, RND)。这一预测误差有效避免了动力学预测中的状态迁移随机性、预测目标不稳定以及预测信号与目标间未知的异质性问题。Ermolov 等人^[82]利用邻近状态对训练了特定的状态隐特征提取网络, 从而在特征表示中去除随机成分, 以其为基础构建前馈的隐世界模型 (latent world model, LWM), 将状态预测误差作为内在奖励。得益于时序关系启发式思想的利用, LWM 算法在多个 Atari-HEG 环境中取得了优于 EMI 算法的分数。然后是预测结果不一致性的方法。前面提及的基于预测误差的方法仅采用单一预测模型的预测误差作为内在奖励, 容易使探索进程受到随机因素影响。最近有研究者提出可以利用多个模型预测结果间的不一致性, 表示状态空间的探索程度。Pathak 等人^[83]提出了 Disagreement 算法, 采用极大似然估计训练一组随机初始化的前向动力学模型, 以不同模型预测的下一时刻状态特征的方差作为内在奖励。在探索程度较低的区域, 此方差值较大, 可激励智能体加强探索; 在较为熟悉的区域, 这些模型的输出都趋向均值, 因此方差较小, 从而避免单模型输出与受随机因素的真实观测间差异较大的情况。而 Shyam 等人^[84]提出的 MAX (model-based active exploration) 算法则利用模型间的信息熵度量其不一致性。这两种算法利用多模型集成的方式, 可以在一定程度上解决随机噪声干扰的问题, 但由于需要训练多个前向动力学模型导致计算复杂度较高。Ratzlaff 等人^[85]利用生成式模型估计智能体对

环境动力学信念的贝叶斯不确定性, 基于此模型的多次采样近似环境的后验表示, 以采样输出的方差作为内在奖励. 在机械臂操控、机器人导航等奖励稀疏的连续场景上的实验结果表明, 该算法的性能表现优于基于模型集成方法^[83-84], 且数据利用率更高. 最后是预测精度提升类的方法. 利用基于预测误差值设计的内在奖励启发智能体探索环境容易因预测误差自身的偏差影响探索过程的稳定性. 针对此问题, 早在 1991 年, Schmidhuber^[86]提出可以量化预测模型的精度提升, 以产生内在奖励信号, 在量化内在动机和驱动探索方面更具鲁棒性. 具体而言, 在对于降低预测误差没有帮助的任务场景 (如远远超出当前技能的挑战、早已熟练掌握的任务以及完全随机而不可控不可学习的环境状态), 智能体不会陷入其中而会寻找对于学习效果更有提升的状态动作空间. 因此这类内在奖励的形式化方法能促进智能体像人类一般具有稳健而循序渐进的心智发育和技能掌握^[67,71]. 早期的一些工作包括 Oudeyer 等人^[71]在 2007 年提出的基于区域划分的预测误差进步评估方法. Lopes 等人^[87]在 2012 年以负对数似然作为预测误差, 以 k 步内误差的提升作为精度提升的量化, 用它替代 BEB^[88]算法中的访问计数, 在简单环境下的探索效率取得显著提升. 近些年, Graves 等人^[89]在模型预测的损失函数基础上, 渐进地设计了多种损失降低 (即精度提升) 或模型复杂度 (即数据编码的容量) 提升的奖励信号. 该算法在合成语言建模等任务上显著提升了学习效率, 在某些情况下甚至提高了一倍的学习效率. 整体来看, 预测误差仍然是这类方法中最主要的“好奇心”内在动机形式. 其中因为对环境状态的预测天然地容易受到环境噪声的影响, 必须辅以谨慎的状态特征提取方法, 才能使智能体仅关注具有探索价值的状态子空间.

参考文献 References:

- [1] MNIEH V, KAVUKCUOGLU K, SILVER D, et al. Human-level control through deep reinforcement learning[J]. nature, 2015, 518(7540): 529-533.
- [2] LILLICRAP T. Continuous control with deep reinforcement learning[J]. arXiv preprint arXiv:1509.02971, 2015.
- [3] HAARNOJA T, ZHOU A, ABBEEL P, et al. Soft actor-critic: Off-policy maximum entropy deep reinforcement learning with a stochastic actor[C]//International con-

ference on machine learning. 2018: 1861-1870.

- [4] RACANIÈRE S, WEBER T, REICHERT D, et al. Imagination-augmented agents for deep reinforcement learning[J]. Advances in neural information processing systems, 2017, 30.
- [5] KUMAR V, TODOROV E, LEVINE S. Optimal control with learned local models: Application to dexterous manipulation[C]//2016 IEEE International Conference on Robotics and Automation (ICRA). 2016: 378-383.
- [6] SCHULMAN J. Trust Region Policy Optimization[J]. arXiv preprint arXiv:1502.05477, 2015.
- [7] SYED U, BOWLING M, SCHAPIRE R E. Apprenticeship learning using linear programming[C]//Proceedings of the 25th international conference on Machine learning. 2008: 1032-1039.
- [8] LUO Y, XU H, LI Y, et al. Algorithmic framework for model-based deep reinforcement learning with theoretical guarantees[J]. arXiv preprint arXiv:1807.03858, 2018.
- [9] KAEHLBLING L P, LITTMAN M L, MOORE A W. Reinforcement learning: A survey [J]. Journal of artificial intelligence research, 1996, 4: 237-285.
- [10] SUTTON R S. Reinforcement learning: An introduction[J]. A Bradford Book, 2018.
- [11] DEISENROTH M, RASMUSSEN C E. PILCO: A model-based and data-efficient approach to policy search[C]//Proceedings of the 28th International Conference on machine learning (ICML-11). 2011: 465-472.
- [12] JANNER M, FU J, ZHANG M, et al. When to trust your model: Model-based policy optimization[J]. Advances in neural information processing systems, 2019, 32.
- [13] AZAR M G, OSBAND I, MUNOS R. Minimax regret bounds for reinforcement learning[C]//International conference on machine learning. 2017: 263-272.
- [14] ZHANG Z, ZHOU Y, JI X. Almost optimal model-free reinforcement learning via reference-advantage decomposition[J]. Advances in Neural Information Processing Systems, 2020, 33: 15198-15207.
- [15] JIN C, ALLEN-ZHU Z, BUBECK S, et al. Is Q-learning provably efficient?[J]. Advances in neural information processing systems, 2018, 31.
- [16] KURUTACH T, CLAVERA I, DUAN Y, et al. Model-ensemble trust-region policy optimization[J]. arXiv preprint arXiv:1802.10592, 2018.
- [17] FEINBERG V, WAN A, STOICA I, et al. Model-based value estimation for efficient model-free reinforcement learning[J]. arXiv preprint arXiv:1803.00101, 2018.

- [18] RAJESWARAN A, MORDATCH I, KUMAR V. A game theoretic framework for model based reinforcement learning[C]//International conference on machine learning. 2020: 7953-7963.
- [19] CHUA K, CALANDRA R, MCALLISTER R, et al. Deep reinforcement learning in a handful of trials using probabilistic dynamics models[J]. Advances in neural information processing systems, 2018, 31.
- [20] KÉGL B, HURTADO G, THOMAS A. Model-based micro-data reinforcement learning: what are the crucial model properties and which model to choose?[J]. arXiv preprint arXiv:2107.11587, 2021.
- [21] ASADI K, MISRA D, KIM S, et al. Combating the compounding-error problem with a multi-step model[J]. arXiv preprint arXiv:1905.13320, 2019.
- [22] EDWARDS A D, DOWNS L, DAVIDSON J C. Forward-backward reinforcement learning[J]. arXiv preprint arXiv:1803.10227, 2018.
- [23] GOYAL A, BRAKEL P, FEDUS W, et al. Recall traces: Backtracking models for efficient reinforcement learning[J]. arXiv preprint arXiv:1804.00379, 2018.
- [24] LAI H, SHEN J, ZHANG W, et al. Bidirectional model-based policy optimization[C] //International Conference on Machine Learning. 2020: 5618-5627.
- [25] LEE K, SEO Y, LEE S, et al. Context-aware dynamics model for generalization in model-based reinforcement learning[C]//International Conference on Machine Learning. 2020: 5757-5766.
- [26] WANG J, LI W, JIANG H, et al. Offline reinforcement learning with reverse model-based imagination[J]. Advances in Neural Information Processing Systems, 2021, 34: 29420-29432.
- [27] VENKATRAMAN A, HEBERT M, BAGNELL J. Improving multi-step prediction of learned time series models[C]//Proceedings of the AAAI Conference on Artificial Intelligence: vol. 29: 1. 2015.
- [28] ASADI K, MISRA D, LITTMAN M. Lipschitz continuity in model-based reinforcement learning[C]//International Conference on Machine Learning. 2018: 264-273.
- [29] VASERSTEIN L N. Markov processes over denumerable products of spaces, describing large systems of automata[J]. Problemy Peredachi Informatsii, 1969, 5(3): 64-72.
- [30] TODOROV E, EREZ T, MUJOCO Y T. A physics engine for model-based control[C] //Proceedings of the 2012 IEEE/RSJ International Conference on Intelligent Robots and Systems: 5026-5033.
- [31] JAAKKOLA T, SINGH S, JORDAN M. Reinforcement learning algorithm for partially observable Markov decision problems[J]. Advances in neural information processing systems, 1994, 7.

- [32] HA D, SCHMIDHUBER J. Recurrent world models facilitate policy evolution[J]. Advances in neural information processing systems, 2018, 31.
- [33] HAFNER D, LILLICRAP T, BA J, et al. Dream to control: Learning behaviors by latent imagination[J]. arXiv preprint arXiv:1912.01603, 2019.
- [34] HAFNER D, LILLICRAP T, NOROUZI M, et al. Mastering atari with discrete world models[J]. arXiv preprint arXiv:2010.02193, 2020.
- [35] HAFNER D, LILLICRAP T, FISCHER I, et al. Learning latent dynamics for planning from pixels[C]//International conference on machine learning. 2019: 2555-2565.
- [36] SHEN J, ZHAO H, ZHANG W, et al. Model-based policy optimization with unsupervised model adaptation[J]. Advances in Neural Information Processing Systems, 2020, 33: 2823-2834.
- [37] BARDES A, PONCE J, LECUN Y. Mc-jepa: A joint-embedding predictive architecture for self-supervised learning of motion and content features[J]. arXiv preprint arXiv:2307.12698, 2023.
- [38] FEI Z, FAN M, HUANG J. A-jepa: Joint-embedding predictive architecture can listen [J]. arXiv preprint arXiv:2311.15830, 2023.
- [39] BARDES A, GARRIDO Q, PONCE J, et al. V-jepa: Latent video prediction for visual representation learning[J]. 2023.
- [40] SUTTON R S. Integrated architectures for learning, planning, and reacting based on approximating dynamic programming[G]//Machine learning proceedings 1990. Elsevier, 1990: 216-224.
- [41] CHEN L P. Mehryar Mohri, Afshin Rostamizadeh, and Ameet Talwalkar: Foundations of machine learning: The MIT Press, Cambridge, MA, 2018, 504 pp., CDN 96.53(*hardback*), ISBN9780262039406[Z]. 2019.
- [42] TESAURO G, GALPERIN G. On-line policy improvement using Monte-Carlo search [J]. Advances in neural information processing systems, 1996, 9.
- [43] TESAURO G, et al. Temporal difference learning and TD-Gammon[J]. Communications of the ACM, 1995, 38(3): 58-68.
- [44] BUCKMAN J, HAFNER D, TUCKER G, et al. Sample-efficient reinforcement learning with stochastic ensemble value expansion[J]. Advances in neural information processing systems, 2018, 31.
- [45] XU T, LI Z, YU Y. Error bounds of imitating policies and environments for reinforcement learning[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2021, 44(10): 6968-6980.

- [46] PAN F, HE J, TU D, et al. Trust the model when it is confident: Masked model-based actor-critic[J]. *Advances in neural information processing systems*, 2020, 33: 10537-10546.
- [47] BOTEV Z I, KROESE D P, RUBINSTEIN R Y, et al. The cross-entropy method for optimization[G]//*Handbook of statistics*: vol. 31. Elsevier, 2013: 35-59.
- [48] WANG T, BA J. Exploring model-based planning with policy networks[J]. *arXiv preprint arXiv:1906.08649*, 2019.
- [49] SILVER D, HUANG A, MADDISON C J, et al. Mastering the game of Go with deep neural networks and tree search[J]. *nature*, 2016, 529(7587): 484-489.
- [50] BROWNE C B, POWLEY E, WHITEHOUSE D, et al. A survey of monte carlo tree search methods[J]. *IEEE Transactions on Computational Intelligence and AI in games*, 2012, 4(1): 1-43.
- [51] CHASLOT G, BAKKES S, SZITA I, et al. Monte-carlo tree search: A new framework for game ai[C]//*Proceedings of the AAAI Conference on Artificial Intelligence and Interactive Digital Entertainment*: vol. 4: 1. 2008: 216-217.
- [52] SILVER D, SCHRITTWIESER J, SIMONYAN K, et al. Mastering the game of go without human knowledge[J]. *nature*, 2017, 550(7676): 354-359.
- [53] SUTTON R S. Dyna, an integrated architecture for learning, planning, and reacting [J]. *ACM Sigart Bulletin*, 1991, 2(4): 160-163.
- [54] MOORE A W, ATKESON C G. Prioritized sweeping: Reinforcement learning with less data and less time[J]. *Machine learning*, 1993, 13: 103-130.
- [55] BELLMAN R. Dynamic programming and stochastic control processes[J]. *Information and control*, 1958, 1(3): 228-239.
- [56] HEES N, WAYNE G, SILVER D, et al. Learning continuous control policies by stochastic value gradients[J]. *Advances in neural information processing systems*, 2015, 28.
- [57] DEGRAVE J, HERMANS M, DAMBRE J, et al. A differentiable physics engine for deep learning in robotics[J]. *Frontiers in neurorobotics*, 2019, 13: 6.
- [58] SEEGER M. Gaussian processes for machine learning[J]. *International journal of neural systems*, 2004, 14(02): 69-106.
- [59] GAL Y, MCALLISTER R, RASMUSSEN C E. Improving PILCO with Bayesian neural network dynamics models[C]//*Data-efficient machine learning workshop, ICML*: vol. 4: 34. 2016: 25.
- [60] MACKAY D J C. Bayesian methods for adaptive models[M]. *California Institute of Technology*, 1992.

- [61] MOHAMED S, ROSCA M, FIGURNOV M, et al. Monte carlo gradient estimation in machine learning[J]. Journal of Machine Learning Research, 2020, 21(132): 1-62.
- [62] CLAVERA I, FU V, ABBEEL P. Model-augmented actor-critic: Backpropagating through paths[J]. arXiv preprint arXiv:2005.08068, 2020.
- [63] BYRAVAN A, SPRINGENBERG J T, ABDOLMALEKI A, et al. Imagined value gradients: Model-based policy optimization with transferable latent dynamics models [C]//Conference on Robot Learning. 2020: 566-589.
- [64] MARTIN J, SASIKUMAR S N, EVERITT T, et al. Count-based exploration in feature space for reinforcement learning[J]. arXiv preprint arXiv:1706.08090, 2017.
- [65] GROSSBERG S. Adaptive Resonance Theory: How a brain learns to consciously attend, learn, and recognize a changing world[J]. Neural networks, 2013, 37: 1-47.
- [66] BALDASSARRE G. What are intrinsic motivations? A biological perspective[C]//2011 IEEE international conference on development and learning (ICDL): vol. 2. 2011: 1-8.
- [67] BARTO A G, SINGH S, CHENTANEZ N, et al. Intrinsically motivated learning of hierarchical collections of skills[C]//Proceedings of the 3rd International Conference on Development and Learning: vol. 112. 2004: 19.
- [68] ARBIB M A. The handbook of brain theory and neural networks[M]. MIT press, 2003.
- [69] HUANG X, WENG J. Novelty and reinforcement learning in the value system of developmental robots[J]. 2002.
- [70] KIM K, SANO M, DE FREITAS J, et al. Active world model learning with progress curiosity[C]//International conference on machine learning. 2020: 5306-5315.
- [71] OUDEYER P Y, KAPLAN F, HAFNER V V. Intrinsic motivation systems for autonomous mental development[J]. IEEE transactions on evolutionary computation, 2007, 11(2): 265-286.
- [72] STADIE B C, LEVINE S, ABBEEL P. Incentivizing exploration in reinforcement learning with deep predictive models[J]. arXiv preprint arXiv:1507.00814, 2015.
- [73] KEMPKA M, WYDMUCH M, RUNC G, et al. Vizdoom: A doom-based ai research platform for visual reinforcement learning[C]//2016 IEEE conference on computational intelligence and games (CIG). 2016: 1-8.
- [74] HOUTHOOFT R, CHEN X, DUAN Y, et al. Vime: Variational information maximizing exploration[J]. Advances in neural information processing systems, 2016, 29.
- [75] KIM H, KIM J, JEONG Y, et al. Emi: Exploration with mutual information[J]. arXiv preprint arXiv:1810.01176, 2018.

- [76] PATHAK D, AGRAWAL P, EFROS A A, et al. Curiosity-driven exploration by self-supervised prediction[C]//International conference on machine learning. 2017: 2778-2787.
- [77] FU J, CO-REYES J, LEVINE S. Ex2: Exploration with exemplar models for deep reinforcement learning[J]. Advances in neural information processing systems, 2017, 30.
- [78] TANG H, HOUTHOOFT R, FOOTE D, et al. # exploration: A study of count-based exploration for deep reinforcement learning[J]. Advances in neural information processing systems, 2017, 30.
- [79] BURDA Y, EDWARDS H, PATHAK D, et al. Large-scale study of curiosity-driven learning[J]. arXiv preprint arXiv:1808.04355, 2018.
- [80] REZENDE D J, MOHAMED S, WIERSTRA D. Stochastic backpropagation and approximate inference in deep generative models[C]//International conference on machine learning. 2014: 1278-1286.
- [81] BURDA Y, EDWARDS H, STORKEY A, et al. Exploration by random network distillation[J]. arXiv preprint arXiv:1810.12894, 2018.
- [82] ERMOLOV A, SEBE N. Latent world models for intrinsically motivated exploration [J]. Advances in Neural Information Processing Systems, 2020, 33: 5565-5575.
- [83] PATHAK D, GANDHI D, GUPTA A. Self-supervised exploration via disagreement [C]//International conference on machine learning. 2019: 5062-5071.
- [84] SHYAM P, JAŚKOWSKI W, GOMEZ F. Model-based active exploration[C]//International conference on machine learning. 2019: 5779-5788.
- [85] RATZLAFF N, BAI Q, FUXIN L, et al. Implicit generative modeling for efficient exploration[C]//International Conference on Machine Learning. 2020: 7985-7995.
- [86] SCHMIDHUBER J. Curious model-building control systems[C]//Proc. international joint conference on neural networks. 1991: 1458-1463.
- [87] LOPES M, LANG T, TOUSSAINT M, et al. Exploration in model-based reinforcement learning by empirically estimating learning progress[J]. Advances in neural information processing systems, 2012, 25.
- [88] KOLTER J Z, NG A Y. Near-Bayesian exploration in polynomial time[C]//Proceedings of the 26th annual international conference on machine learning. 2009: 513-520.
- [89] GRAVES A, BELLEMARE M G, MENICK J, et al. Automated curriculum learning for neural networks[C]//international conference on machine learning. 2017: 1311-1320.

2、课题研究目标、主要研究内容和拟解决的关键问题。Research objectives, main contents and key issues to be solved.

2.1 课题研究目标

本课题围绕基于模型强化学习 (Model Based Reinforcement Learning, MBRL) 中的典型问题, 围绕智能体策略学习与优化性能提升展开研究。从模型的联合误差分析, 高维观测环境的表征, 以及内在驱动的影响三个方面出发, 研究和探索基于 Wasserstein 距离的联合模型误差分析与策略优化方法, 基于模型的表征学习与智能体动作规划方法以及基于模型的内在动机驱动的智能体探索方法。通过这些研究, 提高智能体在模型学习和规划中的性能, 推动基于模型的强化学习方法在实际应用中的推广和应用。

2.2 主要研究内容


本课题旨在提升基于模型的强化学习的策略学习与优化性能, 主要聚焦于三个关键问题: 模型的联合误差分析、高维观测环境的表征以及内在动机驱动对智能体探索的影响。首先, 基于 Wasserstein 距离开展联合模型误差分析, 提出有效的策略优化方法, 以减少模型误差对策略性能的影响。其次, 研究高维环境下的模型表征学习, 探索智能体在复杂环境中的动作规划方法。最后, 探讨基于模型的内在动机驱动, 推动智能体自主探索策略的发展。通过上述研究, 提升智能体在模型学习与规划中的表现, 为基于模型的强化学习在实际应用中的推广提供理论支持和技术保障。

2.3 拟解决的关键问题

首先, 在基于模型的策略优化领域, 现有的转移分布评估指标可能不是最优的, 无法精确衡量模型预测与实际环境之间的误差, 因此需要开发更精细有效的评估方法。其次, 当前的策略优化方法往往只关注模型误差, 而忽略了模型偏移的影响, 这

导致了一个不完整的损失评估。因此，我们需要一个能够综合考虑模型误差和偏移的整体损失评估框架。最后，分支 Rollout 方法的灵活性受到给定 k 值的限制，这影响了数据扩展的能力。为了解决这些问题，我们需要提出新的策略优化方法，以提高模型的准确性和适应性，使其在多样化的应用场景中更加有效。其次，针对于复杂环境，利用表征学习重建的 world model 与真实环境的误差对智能体策略学习的影响的可控性，以及约束这一误差带来最终的策略提升。如何根据任务目标提取环境建立 world model，并保证智能体探索性也是一个重要的问题。最后，在动态、高维环境中的应用仍面临有效状态表示的问题。同时，高位复杂环境中智能体认知效率和复杂任务空间探索也需要优化。

3、拟采取的研究方法、研究方案及其可行性分析。Research methods and research scheme to be adopted and feasibility analysis.



本课题针对上述内三项研究内容，采取问题分析，算法设计，算法实现，数据集验的研究思路。首先对研究问题进行具体分析，找出解决问题的关键点；其次根据问题分析结果，基于相关理论提出合适的算法；然后根据所提算法进行算法实现；最后在公开真实数据集中对算法性能进行验证，并选取相关研究工作进行实验对比。针对最后一项研究内容，采取“系统集成与实现-真实数据集验证-真实场景验证”的研究思路。首先基于前三项的研究内容，通过与环境交互的试错过程来验证方案的

可行性。

课题一：基于 w 距离的模型模型误差分析与策略优化方法：通过引入 Wasserstein 距离作为误差衡量工具，结合模型误差和偏移的联合分析，进一步设计双向可选择 roll-out 机制，最终目标是实现模型的高效优化。

课题二：基于模型的表征学习与智能体动作规划方法：构建用于智能体的环境模型，通过表征学习获取环境的潜在特征。采用自监督学习或变分自编码器（VAE）等深度学习方法，从环境状态和动态中提取低维潜在表示，增强智能体对复杂环境的理解和预测能力。利用基于模型的强化学习（Model-based RL）框架，结合环境模型进行动作规划。通过预测智能体在不同动作下的状态转移，使用蒙特卡洛树搜索（MCTS）或动态规划等方法，优化策略，选择最优动作。迭代优化表征模型与规划算法，基于奖励函数进行评估与调整，提升智能体的决策效率和准确性。

课题三：基于模型的内在动机驱动的智能体探索方法：采用内在奖励机制，引导智能体在缺乏外部奖励的情况下主动探索环境。使用新颖性（novelty）、置信度（confidence）或信息增益等内在动机作为驱动力，促进智能体发现未知或不确定区域。构建环境动态模型，预测智能体的未来状态。通过模型不确定性或预测误差，智能体可以识别探索的关键区域，并结合内在动机优化探索路径。在探索过程中，不断更新环境模型，优化智能体的策略，使其在更有效的探索中获得更高的外在奖励，并提升任务完成效率。

4、课题的创新点 Novelties of the proposed topic.

课题一：基于 w 距离的模型模型误差分析与策略优化方法，包含以下三个创新点：

1. 引入 Wasserstein 距离作为衡量误差指标；
2. 联合模型误差与模型偏移；

3. 设计双向可选择 rollout。

课题二：基于模型的表征学习与智能体动作规划方法，包含以下创新点：

1. 搭建基于表征学习的 world model；
2. 考虑约束误差对智能体学习规划的影响；
3. 提出新的智能体动作规划策略优化方法。

课题三：基于模型的内在动机驱动的智能体探索方法，包含以下创新点：

1. 提出新的学习提升期望驱动的精度提升和信息增益近似方法
2. 搭建状态多样性启发式的最大熵方法：以状态多样性为启发式的最大熵方法，鼓励智能体探索更多样化的状态，以增加策略的泛化能力。
3. 结合表示学习、知识积累、奖励设计、目标空间探索、课程学习、多智能体强化学习等领域的探索方法。

5、计划进度、预期成果 Research schedule, and expected outcomes.

时间安排	主要任务	预期成果
2024.10	学位论文开题	通过开题答辩
2024.11-2025.2	基于表征学习的准确世界模型	一篇或以上论文 (CCF A/B)
2025.3-2025.8	基于模型的内在动机驱动的智能体探索方法	一篇或以上论文 (CCF A/B)
2025.9-2026.1	工作总结与学位论文撰写	完成博士论文

6、与本课题有关的工作积累、已有的研究工作成绩。Prior experience and accomplished achievements related to the proposed topic.

已有成果：

一作：Combined Error Bidirectional Model-based Policy Optimization (ICAR 在审)

合作：E-3DGS: 3D Gaussian Splatting from a Moving Event Camera (AAAI 在审)

本人承诺：开题报告中的内容真实无误，若有不实，愿承担相应的责任和后果。I

hereby declare and confirm that the details provided in this Form are valid and accurate. If anything untruthful found, I will bear the corresponding liabilities and consequences.

学生签字/Signature of Student: 王玥天

日期/Date: 2024-10-19